

机载 LiDAR 波形特征提取及其在地物分类中的应用

王晓晨¹, 张良², 元佳林¹, 蔡湛³, 马洪超^{1*}

1. 武汉大学 遥感信息工程学院, 武汉 430079;

2. 湖北大学 资源环境学院, 武汉 430062;

3. 湖北科技学院 资源环境科学与工程学院, 咸宁 437000

摘要: 针对传统机载 LiDAR 点云数据物理信息缺乏的问题, 提出一种基于波形数据的地物分类的方法, 讨论了各特征对不同地物分类效果的影响。首先对全波形数据进行高斯分解并通过 LM 算法(Levenberg-Marquard Method)对各回波参数进行优化。同时基于波形参数提取 6 个波形特征, 并设置不同的局部空间邻域提取 13 个点云特征。其次对实验数据进行手工划分类别、选择训练样本并选择随机森林算法作为分类器。接着使用 Relief-F 算法对所有特征在分类过程中的权重进行排序。最后根据特征排序结果逐步加入特征, 分析不同特征对各地物类别分类效果的影响。实验结果表明, 使用波形特征与点云特征融合进行分类的效果较好, MIOU 达到 0.87, 总体精度达到 95.4%, Kappa 系数 0.90, 明显优于单一特征分类效果以及传统商业软件 TerraSolid 的地物分类效果。验证了本文方法的有效性、波形特征与点云特征之间的互补性, 具有良好的应用前景。

关键词: 机载 LiDAR, 全波形数据, 波形分解, 特征融合, 地物分类

中图分类号: P237

文献标志码: A

引用格式: 王晓晨, 张良, 元佳林, 蔡湛, 马洪超. 2020. 机载 LiDAR 波形特征提取及其在地物分类中的应用.

1 引言

地物分类在环境监测、地质调查、农业勘测以及城乡规划等领域具有广阔的应用前景(Elizarov *et al.* 2016; Terefenko *et al.* 2019; Turner *et al.* 2014; Stefanov *et al.* 2015)。自上世纪 80 年代以来, 机载激光雷达(Airborne LiDAR System, ALS)快速发展, 已成为遥感数据采集技术的一种重要方式。

传统的机载激光雷达只能提供离散三维点云数据和回波强度信息, 这些有限的信息使得地物分类的精度受到很大的制约。针对这一问题, 许多学者致力于通过多源数据融合的方法来弥补点云物理信息的缺乏。陈奇(2015)提出一种基于数据互补的方法, 综合利用 LiDAR 数据和遥感影像数据获取高精度的建筑物检测结果; Alonso(2008)提出一种点云和航空影像相结合的方法, 进行土地利用变化检测; 刘小萍(2018)使用高光谱遥感影像和机载 LiDAR 数据进行融合, 并用于提取土地利用信息; 董彦芳(2014)采取高光谱数据和机载 LiDAR 数据融合的方法来提取城市中房屋和树木等地物目标。但是, 对于这些同时相多元数据融合的分类方法存在对数据完备性要求过高的问题, 具有很大的局限性(Ozkan and Akar, 2019)。由此, 亟需一种快速高效、简单便捷的解决方案以弥补传统机载激光雷达数据中物理信息的不足。

2004 年奥地利 Riegl 公司生产的机载 LiDAR 扫描系统 LMS-Q560 进入市场, 宣布了全波形时代的

到来。全波形激光扫描系统对激光信号采用了另外一种不同的量化方式, 其将发射信号和回波信号均以很小的间隔(一般为 1-2ns)进行采样并记录, 得到一个连续的高分辨率回波波形。全波形数据中蕴藏着丰富的信息, 通过对回波波形数据进行波形分解可以得到更多的地物几何和物理特征, 这补充了传统机载 LiDAR 离散点云数据物理信息的不足, 而且不存在多源数据融合对数据完备性要求过高的问题。Jutzi(2007)把全波形数据应用于距离检测, 可以区分出在光斑内小于脉冲长度十分之一的阶梯表面; Moritz (2017)使用机载 LiDAR 全波形数据并提取统计学特征对树种进行分类; Koma(2016)在城市区域内进行树种分类, 实验证明波形特征在分类中具有很大的应用潜力, 但是易受汽车、栅栏等干扰物的影响。Wu(2016)探讨了波形数据在植被区域的处理能力, 并从两个方面设计指标进行评价。

本文以机载 LiDAR 全波形数据为研究对象, 综合利用点云特征与波形特征进行地物分类, 主要贡献包括以下两部分:

1) 融合点云特征与波形特征, 兼顾考虑地物的空间几何信息与物理信息进行分类并取得了较好的效果。

2) 对分类特征进行排序, 分析各特征对不同地物分类效果的影响。

2 实现方法及流程

本文研究主要涉及高斯分解、特征提取、融合

收稿日期: ****-**-**; 修订日期: ****-**-**; 优先数字出版日期: ****-**-**

基金项目: 国家自然科学基金项目 (编号: 41601504), 高分辨率对地观测系统重大专项 (编号: 11-H37B02-9001-19/22), 国家重点研发计划项目 (编号: 2018YFB0504500)

第一作者简介: 王晓晨(1998—), 男, 硕士, 现从事机载激光雷达点云与波形数据处理研究。Email: xchwang@whu.edu.cn

地物分类以及分析不同特征对地物分类效果的影响 等方面, 整体实验流程如图 1 所示:




图 1 本文整体实验流程图
Fig.1 Experimental framework of this paper

2.1 数据预处理

全波形数据在采集过程中不可避免的会受到环境、传感器自身的影响而产生一些噪声。噪声在原始波形中体现为一些小的抖动, 这些小抖动会对后续的波形处理步骤产生很多干扰, 如被错误判断为波峰, 导致检测的波峰个数远远大于真实值。针对全波形数据本文中采用单一阈值法去除背景噪声, 并通过窗口大小为 5 的高斯模板对经过阈值去噪的数据进行平滑处理以去除随机噪声。经过数据预处理后, 既消除了噪声的影响又保留了主要的波形信息(形状、位置等)。

2.2 高斯分解

2.2.1 波形参数初值

高斯分解法认为波形数据是由一系列单个波组成的且这些成分可以简化为高斯函数。每个高斯回波对应应有三个参数 A_i^0 , μ_i^0 , ω_i^0 用于描述回波的形状, 如图 2 中所示。这些参数初值的确定对于波形分解的精度十分重要, 一个较优的初值可以避免陷入局部最优的情况。例如, 振幅初值 A_i^0 的设定易受到噪声的影响而产生较大误差, 导致在后续优化过程中高斯回波分量幅值升高。波峰位置 μ_i^0 、半波宽 ω_i^0 参数初值设定不准确则会导致高斯回波的位置发生整体偏移以及与原波形的拟合度较差。

基于此, 本文通过计算梯度(二阶导数)获取各参数的初值(Hofton et al. 2000)。这些参数的初值并不能代表真实值, 还需要对其进行优化以得到精确的参数。

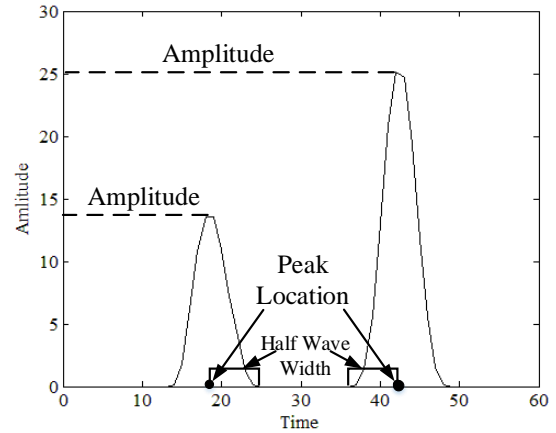


图 2 波形参数初值示意图
Fig.2 The initial value of waveform parameters

2.2.2 LM 算法波形校正

目前, 国内外学者提出了一系列的方法用于波形参数初值优化。本文采用列文伯格-马夸尔特算法(Levenberg-Marquardt, LM), 其通过调整自身的阻尼因子大小来控制收敛的步长, 结合了梯度下降法、高斯-牛顿法这两种方法的优点, 已成为适用性最强的非线性最小二乘算法之一。针对本文中求解最优波形参数的问题能够取得较好效果。主要操作步骤描述如下:

- 1) 设 $x \in R_m$ 为参数向量, $y \in R_n$ 为观测向量, ξ 为观测值 y 与估值 \hat{y} 之间的差值。

$$\hat{y} = f(x) \quad (1)$$

$$\xi = y - \hat{y} \quad (2)$$

- 2) 对于一个足够小的值 ∂_x ，可以将 $f(x)$ 通过泰勒级数线性展开。

$$f(x + \partial_x) \approx f(x) + J\partial_x \quad (3)$$

式中 J 为雅克比矩阵 $\frac{\partial f(x)}{\partial(x)}$ 。

- 3) 迭代，且在每一次迭代过程中寻找一个局部最优值 ∂_x ，最终使得式 (4) 的结果最小。

$$y - f(x + \partial_x) \approx y - f(x) - J\partial_x = \xi - J\partial_x \quad (4)$$

- 4) 当向量 $\xi - J\partial_x$ 与 J 的列向量正交时，式 (4) 取得最小值，转换为标准形式。

$$J^T J \partial_x = J^T \xi \quad (5)$$

- 5) 对海瑟矩阵 $J^T J$ 的对角线元素添加阻尼因子 u 以防止出现矩阵奇异，并通过自适应调节 u 的大小收敛速度。

$$N_{ii} = u + [J^T J]_{ii} \quad (6)$$

代入式 (5) 得：

$$N\partial_x = J^T \xi \quad (7)$$

- 6) 计算出 ∂_x ，对各参数值进行改进。

$$x_i = x_{i-1} + \partial_x \quad (8)$$

- 7) 利用改正后的参数值计算经过本次迭代后的残差 ξ ，若本次的残差平方和 $\xi^T \xi$ 小于预先设置的阈值或者当前迭代中波形参数的改进步长 ∂_x 趋于稳定，则停止迭代；否则，若本次迭代的残差平方和小于前一次的计算结果则增加阻尼因子 u ，若本次迭代的残差平方和大于前一次的计算结果则减少阻尼因子 u ；然后重复执行上述步骤 3-6。




图 3 全波形数据高斯分解结果

Fig.3 Results of full waveform data Gaussian decomposition

经过上述 LM 算法优化，波形数据被分解为多

个高斯回波组分。如图 3 中所示，黑色实线为经过预处理后的波形数据，蓝色虚线、红色虚线、绿色虚线以及紫色虚线分别为波形分解后的四个高斯回波分量，能够精确的描述原始波形。

2.3 分类特征提取

传统机载 LiDAR 点云数据本身一般具有三维坐标、强度信息以及回波信息等，这些有限的信息对于地形平缓区域的简单分类一般可以获得较高精度，但对于复杂地形或多种地物分类（如本文）的情况，则明显不够。由此，本文有必要进行特征提取操作，以更好的描述不同类别之间的区别。

2.3.1 波形特征

本文对波形分解得到的参数进行处理，生成了振幅、波峰位置、半波宽、回波个数、回波强度、后向散射系数等波形特征，用于描述地物的物理特性。下面将分别介绍这 6 个特征的含义及其计算方式。

(1) 振幅：经过 LM 算法优化后的波形参数 即为回波的振幅，其随着不同物体的辐射和几何特性而变化。Alexander(2010)研究表明：草地、裸土一般具有较高的振幅，建筑物则根据屋顶材料的不同具有不同的振幅值。

(2) 波峰位置：经过 LM 算法优化后的波形参数 μ_i 即为回波的波峰位置。其代表了发射脉冲与目标物产生响应的位置与回波脉冲初始记录之间的时间间隔，实质就是传感器与激光脚点之间的距离。

(3) 半波宽：经过 LM 算法优化后的波形参数 ω_i 即为半波宽，回波形状的变化与地物类型密切相关。

(4) 回波个数：回波分量的个数，实验表明，对于地面点、屋顶面点多为单个回波分量，而对于低矮植被点、高植被点等粗糙表面则有多回波分量。

(5) 回波强度：回波强度信息定义为目标反射到传感器能量的大小。可以通过波形分解得到的参数进行计算，见公式 (9)。

$$intensity = \sqrt{2\pi} A_i \omega_i \quad (9)$$

式中 A_i 为回波振幅， ω_i 为半波宽。

(6) 后向散射系数：雷达方程的推导过程中引入了后向散射截面，其被定义为激光脉冲与地面的有效碰撞面积，可以通过公式 (10) 进行计算。

$$\sigma = C_{cal} R^4 \frac{A_w}{\alpha^2} \Gamma \left(\frac{1}{\alpha^2} \right) \quad (10)$$

式中 C_{cal} 为定标常数，且可以通过公式 (11) 进行计算； Γ 是伽马函数，代表传感器对回波的影响。

$$C_{cal} = \frac{\pi \rho_{asphalt} \beta^2}{R^2 A_{asphalt} w_{asphalt}} \quad (11)$$

实际应用中认为沥青为一个朗伯体，式中 A_{aspha} 、 $w_{asphalt}$ 、 $\rho_{asphalt}$ 分别代表沥青材料回波的振幅、半波宽及反射系数。

后向散射系数 γ 是一个标准化的物理属性，代表通过单位激光束覆盖面积的后向散射截面，计算见公式 (12)。

$$\gamma = \frac{\sigma}{A_{laser}} \quad (12)$$

式中 σ 为后向散射截面， A_{laser} 为激光束覆盖面积，计算见公式 (13)。

$$A_{laser} = \frac{\pi R^2 \beta^2}{4} \quad (13)$$

式中 R 为激光束到地面的距离， β 是激光束发散角。

2.3.2 点云特征

基于激光点的高程或邻域点的空间分布，本文提取阶跃数、高程相关、剖面相关以及密度相关等类型的点云特征作为点云的几何描述。

(1) 阶跃数：其是 Guo(2015)提出的一个基于格网邻域的特征。计算该特征的主要思路为：在当前点所在格网的 8 个相邻方向中依次搜索并统计格网最低点高差大于给定阈值的方向数。

(2) 高程相关：本文中基于圆柱邻域进行提取高程相关特征，圆柱体邻域是 Lalonde(2010)提出的一种二维邻域，其以当前点为中心，半径为 $R_{cylinder}$ ，不考虑高程限制而形成的直圆柱。在搜索圆柱邻域内的激光脚点时，只需要确定当前点与其余各点的二维欧氏距离，见公式 (14)。

$$\sqrt{(x_i - x_j)^2 + (y_i - y_j)^2} \geq R_{cylinder} \quad (14)$$

式中 $R_{cylinder}$ 为圆柱体邻域的半径， (x_i, y_i) 为当前点的平面坐标， (x_j, y_j) 为搜索点的坐标。

(3) 剖面相关：与高程相关特征类似，剖面相关特征也是基于圆柱体邻域进行提取。本文按照一定高度 (0.5 m) 把圆柱体邻域的剖面划分为若干个网格。

(4) 密度相关：球体邻域是 Lalonde(2010)提出的一种三维邻域，其是以当前点为中心，为半径形成的球体中所有激光脚点组成的集合。

2.4 分类器及特征选择

机载 LiDAR 点云处理总是涉及大量数据，如何快速、准确地对其进行数据分析是一个挑战。Breiman(2000)提出了随机森林分类器，一种基于决策树的集成学习方法。针对本文中所要处理的大量点云数据多分类的问题，随机森林在处理速度、样本类别不平衡、泛化能力等方面有其他分类器所不具备的优势。

特征选择的实质是从全局集合中选取一个相关特征子集的技术，这使得研究者能够了解波形特征对于从三维离散点云中提取的点云特征的实际附加值。此外，一些相关性较低的特征对于分类效果不仅没有提升还可能对其产生负面影响，而进行特征选择则可以去除这些冗余特征的干扰(Mallet *et al.* 2008)。过滤式特征选择算法与分类过程独立完成(黄莉莉, 2013)，计算效率较高，且可以较容易的扩展到高维数据集中(李晓岚, 2013)。此外，由一种过滤式特征选择算法得到的特征评价结果可以直接应用于多种不同的分类器中。Relief 算法由(Kira, 1992)提出，是最成功的过滤式特征选择算法之一。其通过考察特征在同类样本与异类样本之间的差异来度量该特征的区分能力，避免了使用全局搜索及启发式搜索方法，相对于封装式算法具有更高效的性能。传统 Relief 算法只能应用在两类数据的特征选择中，然而实际应用中存在大量的多类问题。因此 Kononenko(1994)在 Relief 算法的基础上提出 Relief-F 算法来处理多分类问题，并且补充了对不完整数据的处理。Zhang(2008)结合使用 Relief-F 算法以及 mRMR 算法对 7 种不同的生物基因数据集进行特征选择，结果表明可以获取该方法具有较高的执行效率且可以获得最优的基因表达。Zeng(2013)基于 PCA 和 Relief-F 算法进行特征选择，实验结果表明可以找到最优的特征子集，并在大多数情况下实现了比原始特征更高的识别精度。Mallet(2011)利用全波形数据分别通过 F-score，Relief-F 以及 SVM-RFE 三种特征选择算法对城市区域地物分类，实验结果表明 Relief-F 算法进行排序的前 18 个特征子集达到了最高精度。基于此，本文以 Relief-F 算法对波形特征与点云特征在分类过程中的重要性进行评价，并根据评价结果分析不同特征对地物分类的影响。Relief-F 算法使用每个类别中所有实例的 K 最近邻 (本文中 K 设置为 10) 来计算所有特征的权重。其具体实施步骤如图 4 所示：




图 4 Relief-F 算法实现过程
Fig.4 Implementation of Relief-F algorithm

3 实验结果与分析

3.1 实验数据

本文所采用的实验数据来自于中国北京市某地区，覆盖面积约为 $40530m^2$ ，点云的平均密度约为 5 点/平方米。实验数据类别划分为地面点、建筑物点、低矮植被点、高植被点四类，其真实结果在武汉天擎空间信息技术有限公司提供的机载雷达数据后处理软件 LiDAR_Suite v4.6 中人工分类完成，如图 4 所示。同时，针对实验数据中不同类别的激光脚点数据分布不均匀、总体分布规律难以获取的问题，且考虑到数据的相关性与地理分布信息，本文采取了人工选择样本的方式，致力于满足以下三个特性(Ma *et al.* 2018):

- (1) 可以代表此实验数据区域的地形特征。
- (2) 包含实验数据的所有类别。
- (3) 均匀分布。




图 5 实验数据手工分类并选择训练区
Fig.5 Manually classify experimental data and select

training areas

如图 5 中所示，本文在实验区域划分为 $5*5$ 的网格并从中选取了其中的 5 个网格作为训练区。

3.2 精度评价与对比

首先，本文采用了无选择的特征融合方法进行分类，即波形特征与点云特征直接相结合而不做任何选择，分类效果如图 6 所示。




图 6 无选择特征融合分类效果
Fig.6 Classification effect of non-selective feature fusion

图 6 中红色区域为建筑物点，深绿色代表高植被点、浅绿色代表低矮植被点，棕色区域为地面点。通过目视分析可以看出整体分类效果较好，但是仍存在问题主要表现在：1) 建筑屋顶面中心区域与地面点相互混淆。2) 实验右侧偏上区域存在少许地面点与低矮植被点、建筑物点与低矮植被点相混淆的情况。

上述仅通过目视解译对其进行分析过于简略，下面本文基于混淆矩阵，利用漏分误差、错分误差、交并比 (Intersection over Union, IoU)、平均交并比 (Mean Intersection over Union, MIoU)、总体精度 (Overall Accuracy, OA)、Kappa 系数等客观指标对分类的实验结果进行精度评定，如表 1 中所示。

表 1 波形特征与点云特征无选择融合分类结果精度评定

Table 1 Accuracy assessment of non-selective fusion classification results based on waveform features and point cloud features

		预测类别				
真实类别	地面	132844	1664	214	1745	漏分误差(%)
	低植被	2951	29488	198	409	10.77
	高植被	8	251	9932	33	2.86
	建筑物	1017	338	83	11770	10.89
	错分误差(%)	2.91	7.10	4.75	15.67	
	IoU	0.95	0.84	0.93	0.76	
总体精度: 95.4%		Kappa 系数: 0.90		MIoU: 0.87		

由表 1 中数据分析可知，使用波形特征与点云特征融合对实验区域进行分类的效果较好，MIoU 达到 0.87，总体精度达到 95.4%，Kappa 系数 0.90。地面点、高植被点错分误差及漏分误差的值都相对

较小且 IoU 值均在 0.9 以上，具有较好的分类效果。同时，实验数据中也存在建筑物、低矮植被分类过差的问题，单类别 IoU 值仅 0.76、0.84，漏分误差达到 10% 以上且都与地面点相互混淆。

尽管上述实验表明直接使用两种类型的特征进行分类取得了较好的效果,但是高维度的特征向量带来了巨大的计算消耗,而且简单的进行组合并不能了解这些特征之间的相关性。由此,本文基于上述研究内容使用了一种滤波式算法 Relief-F 对波形特征与点云特征进行选择。

基于 3.1 节中人工选择的训练集利用 Relief-F 算法计算每种特征的权重并进行排名,排名结果如图 7 中所示。

由图 7 中可知,在波形特征中振幅 A 表现较好;点云特征中最大负高差 MN、最大正高差 MP、最大网格高程方差 MV、点密度 PD 以及高程变化范围 ER 表现较好,在特征排序中占有较高的权重。




图 7 Relief-F 算法特征排序

Fig.7 Feature ranking by Relief-F algorithm

本文根据 Relief-F 算法的权重排序结果逐次加入特征,同时为了更加细致的分析逐步加入特征对分类效果的影响,本文分别计算实验数据中地面点、低矮植被、高植被、建筑物四种类别的漏分误差与错分误差,并对其变化趋势进行分析,如图 8 所示。




图 8 单一类别误差变化趋势

Fig.8 Error trend of single category

图 8 中黑色曲线代表漏分误差,红色曲线代表错分误差,(a)-(d)分别为地面点、低矮植被、高植被、建筑物四种地物的漏分误差与错分误差随分类特征数量增加的变化趋势。由图 8 (a)可知,地面点的错

分误差在前 5 个特征(最大负高差 MN、最大网格高程方差 MV、点云密度 PD、最大正高差 MP、高程方差 EV)以及第 8 个特征(振幅 A)加入后有明显的下降,在加入第 9、10 个特征(阶跃数 S、高

差峰度 HK) 时其漏分误差却出现大幅度上升, 错分误差也有所起伏。由图 8 (b) 可知, 加入前 5 个特征使得低矮植被点的漏分误差及错分误差均有明显下降, 后续特征的加入使得其漏分误差有小幅度起伏, 错分误差则呈现缓慢下降的趋势。由图 8(c) 可知, 在加入前 8 个特征时, 高植被点的漏分误差及错分误差均呈下降趋势。随后其漏分误差趋于稳定而在加入第 9、10 个特征以及第 14 个特征 (高差偏度 HS) 时, 其错分误差却出现大幅度上升。由图 8 (d) 可知, 对于建筑物点的漏分误差受前 4 个特征的影响较大, 而后续特征的加入则趋于稳定。其错分误

差起伏较大但仍总体仍呈现下降趋势, 在加入第 3、6、15 个特征 (最大网格高程方差 MV、高差均值 EA、回波数 EN) 时错分误差出现上升趋势, 而在加入第 5、9、13、17 的特征 (高程方差 EV、阶跃数 S、非空网格数 NG、半波宽 ω) 时, 其错分误差有明显下降。

此后, 为定量评价加入波形特征后对地物分类的影响, 本文针对不同的特征组合设计了四组实验并评定分类精度进行对比, 得到的统计结果如表 2 中所示。

表 2 实验结果统计
Table 2 Statistics of experimental results

	点云		波形		点云+波形		Relief-F (14 个)		TerraScan	
	漏分	错分	漏分	错分	漏分	错分	漏分	错分	漏分	错分
地面	4.03	3.22	7.45	13.23	2.65	2.91	3.12	2.56	26.48	1.63
低植被	11.77	8.56	33.52	30.86	10.77	7.10	8.73	7.81	5.59	55.32
高植被	2.59	4.56	63.59	32.65	2.86	4.75	3.23	4.64	8.21	16.45
建筑物	11.71	23.75	48.06	31.92	10.89	15.67	11.92	17.88	26.45	1.74
MIoU	0.81		0.72		0.87		0.86		0.67	
总体精度	94.20		82.33		95.40		95.31		78.07	

由表 2 可见, 波形特征与点云特征融合后进行分类相对单独使用一类特征的效果均有较大提升。另外, 本文使用 Relief-F 算法排序, 根据排序结果选择其中前 14 个特征进行分类, 其总体精度可以达到 95.31%, MIoU 达到 0.86。最后与通用 LiDAR 数据后处理商业软件 TerraSolid 中的 TerraScan 模块分类效果进行比较, 对比发现本文中使用两类特征对四类地物的分类效果明显占优。

此外, 对于本文中的分类问题研究有必要与其他方法进行对比。但是, 目前机载 LiDAR 波形数据相对缺乏, 国内外仍未见有相关公共数据集发布。因此, 本文采取与近年来多种分类方法在地貌、地物类型均类似的实验区域分类精度进行横向对比, 如表 3 中所示。

表 3 各分类方法对比
Table 3 Comparisons between ours and other state-of-art methods

	分类方法	总体精度	Kappa 系数
Gu <i>et al.</i> 2016	MKSRC	98.10%	0.9624
Xu <i>et al.</i> 2018	3D CNN	92.57%	0.9153
Li <i>et al.</i> 2019	PLR+GSR -G _{opt}	97.17%	/
赵传 2020	DRN	87.1%	/
Wen <i>et al.</i> 2020	D-FCN	95.6%	/
Ours	Waveform+ Point Cloud	95.4%	0.90

4 结论

本文以包含复杂地物分布的实验区域为研究对象, 在传统 13 个点云特征的基础上引入全波形数据分解提取的 6 个波形特征对实验数据进行地物分类, 主要得出以下几点结论:

(1) 使用点云特征与波形特征进行分类可以取得较好的分类效果, MIoU 达到 0.87, 总体精度达到 95.4%, Kappa 系数 0.90。同时, 分类结果中也存在建筑物与地面点、低矮植被与地面点之间相互混淆的问题。

(2) 基于 ReliefF 算法排序结果可以得出: 在波形特征中振幅 A 表现较好, 点云特征中最大负高差 MN、最大正高差 MP、最大网格高程方差 MV、点密度 PD 以及高程变化范围 ER 表现较好, 在分类过程中占有较高的权重。

(3) 逐步加入各特征进行分类并对分类结果进行精度评价, 分析可得: 加入前 5 个特征 (最大负高差 MN、最大网格高程方差 MV、点云密度 PD、最大正高差 MP、高程方差 EV) 以及第 8 个特征 (振幅 A) 对地面点、低矮植被点、高植被点、建筑物点的分类效果均有一定提升。然而, 也存在加入新特征对地物分类效果产生负面影响的情况, 如加入第 9、10 个特征 (阶跃数 S、高差峰度 HK), 地面

点与高植被点的分类误差值呈现上升趋势。

综上, 本文提出一种基于波形数据的地物分类的方法, 讨论了各特征对不同地物分类效果的影响, 验证了全波形数据应用于复杂区域地物分类的可行性。

志谢 本文中部分实验数据由武汉天擎空间技术有限公司提供, 在此表示衷心的感谢。

参考文献(References)

- Alexander C , Tansey K , Kaduk J , et al. 2010. Backscatter coefficient as an attribute for the classification of full-waveform airborne laser scanning data in urban areas[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*. 65:423-432. doi:10.1016/j.isprsjprs.2010.05.002
- Alonso J A M M C . 2008. A method for change detection with multi temporal satellite images using the RX algorithm [J]. *Int Arch Photogramm Remote Sens Spat Inf Sci*, 37:1631-1635.
- Breiman L. 2001. Random Forests [J]. *Machine Learning*. 45(1): 5-32. doi:10.1023/A:1010933404324
- Chen Q. 2015. Research on methods of building detection and contour refinement by fusing LiDAR data and airborne images [D]. WuHan: WuHan University. (陈奇. 2015. 机载 LiDAR 与影像结合的建筑物检测及其轮廓精化方法研究 [D]. 武汉: 武汉大学.)
- Dong Y , Pang Y , Xu L , Chen L . 2014. Feature extraction based on fusion of hyperspectral image and airborne LiDAR data[J]. *Remote Sensing Information*, 29(06):73-76,83. (董彦芳, 庞勇, 许丽娜, 陈立泽. 2014. 高光谱遥感影像与机载 LiDAR 数据融合的地物提取方法研究 [J]. 遥感信息, 29(06):73-76,83.) [DOI:10.3969/j.issn.1000-3177.2014.06.015]
- Elizarov V V , Grishkanich A S , Kascheev S V , et al. 2016. Lidar scanning module for remote environmental monitoring[C]// 2016 International Conference Laser Optics (LO). IEEE. doi:10.1109/LO.2016.7549820
- Guo B , Huang X , Zhang F , et al. 2015. Classification of airborne laser scanning data using JointBoost[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*. 100:71-83. doi:10.1016/j.isprsjprs.2014.04.015
- Gu Y , Wang, Q , Xie, B. 2016. Multiple Kernel Sparse Representation for Airborne LiDAR Data Classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(2), 1085-1105. doi:10.1109/tgrs.2016.2619384
- Hofman M A , Minster J B , Blair J B . 2000. Gaussian Decomposition of Laser Altimeter Waveforms[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 38(4):1989-1996. doi:10.1109/36.851780
- Huang L. 2013. The research of multi-label learning problem about feature selection and classification[D]. HeFei: Anhui University. (黄莉莉. 2013. 多标签学习中特征选择和分类问题的研究[D]. 合肥: 安徽大学.)
- Jutzi B , Stilla U . 2007. Range determination with waveform recording laser systems using a Wiener Filter[J]. *Isprs Journal of Photogrammetry & Remote Sensing*. 61(2):95-107. doi:10.1016/j.isprsjprs.2006.09.001
- Kira K , Rendell L A . 1992. A Practical Approach to Feature Selection[C]// *International Workshop on Machine Learning*. Morgan Kaufmann Publishers Inc. doi:10.1016/B978-1-55860-247-2.50037-1
- Koma, Z.; Koenig, K.; Höfle, B. 2016. Urban tree classification using full-waveform airborne laser scanning. *Isprs Annals of Photogrammetry Remote Sensing & Spatial Informa. Sci*. 3:185-192. doi:10.5194/isprs-annals-III-3-185-2016
- Kononenko I . 1994. Estimating attributes: Analysis and extensions of RELIEF[C]// *European Conference on Machine Learning*. Springer, Berlin, Heidelberg. doi:10.1007/3-540-57868-4_57
- Lalonde J F , Vandapel N , Huber D F , et al. 2010. Natural terrain classification using three-dimensional lidar data for ground robot mobility[J]. *Journal of Field Robotics*. 23(10):839-861. doi:10.1002/rob.20134
- Li N , Liu C , Pfeifer N . 2019. Improving LiDAR classification accuracy by contextual label smoothing in post-processing[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 148(FEB.):13-31. doi:10.1016/j.isprsjprs.2018.11.022
- Liu X. 2018. Research on Land Use Information extraction method based on airborne LiDAR data and hyperspectral data[D]. JiNan: Shandong Normal University. (刘小萍. 2018. 基于机载 LiDAR 和高光谱数据的土地利用信息提取方法研究[D]. 济南: 山东师范大学.)
- Li X. 2013. The study and application of feature selection algorithms based on Relief[D]. DaLian: Dalian University of Technology. (李晓岚. 2013. 基于 Relief 特征选择算法的研究与应用[D]. 大连: 大连理工大学.)
- Mallet C , Soergel U , Bretar F . 2008. Analysis of Full-Waveform Lidar Data for Classification of Urban Areas [J]. *Photogrammetrie fernerkundung geoinformation*. 5(5):37-49. doi:10.1117/12.773279
- Mallet C , Bretar F , Roux M , et al. 2011. Relevance assessment of full-waveform lidar data for urban area classification[J]. *Isprs Journal of Photogrammetry & Remote Sensing*. 66(6S):S71-S84. doi:10.1016/j.isprsjprs.2011.09.008
- Ma H , Cai Z , Zhang L . 2018. Comparison of the filtering models for airborne LiDAR data by three classifiers with exploration on model transfer[J]. *Journal of Applied Remote Sensing*. 12(1):1. doi:10.1117/1.JRS.12.016021
- Moritz, Bruggisser, Andreas, et al. 2017. Retrieval of higher order statistical moments from full-waveform LiDAR data for tree species classification[J]. *Remote Sensing of Environment*. 96:28-41. doi:10.1016/j.rse.2017.04.025
- Ozkan S , Akar G B . 2019. Hyperspectral Data to Relative Lidar Depth: An Inverse Problem for Remote Sensing[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). IEEE. doi:10.1109/CVPRW.2019.00126.
- Stefanov W L , Ramsey M S , Christensen P R . 2015. Monitoring urban land cover change: An expert system approach to land

- cover classification of semiarid to arid urban centers[J]. *Remote Sensing of Environment*, 77(2):173-185. doi:10.1016/S0034-4257(01)00204-8
- Terefenko, Paweł, Paprotny D , Giza A , et al. 2019. Monitoring Cliff Erosion with LiDAR Surveys and Bayesian Network-based Data Analysis[J]. *Remote Sensing*, 11(7). doi:10.3390/rs11070843
- Turner R , Panciera R , Tanase M A , et al. 2014. Estimation of soil surface roughness of agricultural soils using airborne LiDAR[J]. *Remote Sensing of Environment*, 140(140):107-117. doi:10.1016/j.rse.2013.08.030
- Wen C , Yang L , Peng L , et al. 2020. Directionally Constrained Fully Convolutional Neural Network For Airborne Lidar Point Cloud Classification[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 162(Apr):50-62. doi:10.1016/j.isprsjprs.2020.02.004.
- Wu J , Van Aardt J A N , Asner G P . 2011. A Comparison of Signal Deconvolution Algorithms Based on Small-Footprint LiDAR Waveform Simulation[J]. *IEEE Transactions on Geoece & Remote Sensing*, 49(6):2402-2414. doi:10.1109/TGRS.2010.2103080
- Xu Z , Guan K , Casler N , et al. 2018. A 3D convolutional neural network method for land cover classification using LiDAR and multi-temporal Landsat imagery[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 144(OCT.):423-434. doi:10.1016/j.isprsjprs.2018.08.005
- Zhang Y , Ding C , Li T . 2008. Gene selection algorithm by combining Relief-F and mRMR[J]. *Bmc Genomics*. 9:27. doi:10.1186/1471-2164-9-S2-S27
- Zhao C , Guo H , Lu J, et al. 2020. Airborne LiDAR point cloud classification based on deep residual network[J]. *Acta Geodaetica et Cartographica Sinica*, 49(2):202-213. (赵传, 郭海涛, 卢俊, 等. 2020. 基于深度残差网络的机载 LiDAR 点云分类 [J]. *测绘学报*, 49(2):202-213.) [doi:10.11947/j.AGCS.2020.20190004.]
- Zeng X , Wang Q , Zhang C , et al. 2013. Feature selection based on Relief-F and PCA for underwater sound classification[C]// 2013 3rd International Conference on Computer Science and Network Technology (ICCSNT). IEEE. doi:10.1109/ICCSNT.2013.6967149

Waveform Feature Extracted from Airborne LiDAR and Its Application in the Classification of Land-cover

WANG Xiaochen¹, ZHANG Liang², YUAN Jialin¹, CAI Zhan³, MA Hongchao^{1*}

1. School of Remote Sensing and Information Engineering, Wuhan University, Wuhan, 430079, China

2. School of Resources and Environmental Science, Hubei University, Wuhan, 430062, China

3. School of Resources Environment Science and Technology, Hubei University of Science and Technology, Xianning, 437000, China

Abstract: **Objective** Airborne LiDAR (Light Detection and Ranging) is an active earth observation system that integrates high-precision inertial measurement unit (IMU), global positioning system (GPS), and laser scanning ranging system. Though it's various advantages, such as fast speed, high resolution, and strong penetration ability, it is lack of physical information to a large extent. Aiming at this problem in traditional airborne LiDAR point cloud data, a method of land-cover classification based on waveform LiDAR data is proposed, and the influence of each feature on the classification of different ground features is discussed. **Method** The implementation of our method can be summarized as following four key steps: 1) Firstly, we use the Gaussian decomposition algorithm to process full-waveform data and each echo parameter is optimized by LM (Levenberg-Marquard) algorithm. Simultaneously, 6 waveform features are extracted based on the echo parameters, and 13 point cloud features are extracted based on different local spatial neighborhoods. 2) Secondly, the experimental data are classified manually, the training samples are selected and the random forest algorithm is selected as the classifier. 3) After that, Relief-F is used to rank the weights of all features in the classification process. 4) Finally, according to the result of feature ranking, the features are gradually added to analyze the influence of different features on the classification effect of each object category. Compare the effects of using different feature combinations and commercial software TerraSolid for classification of land-cover. **Result** In this paper, we use a full-waveform LiDAR data set from a certain area of Beijing, China, covering approximately 40,530 square meters to verify our method. The experimental result shows that the fusion of waveform features and point cloud features is most effective, MIoU is 0.87, overall accuracy is 95.4%, and the Kappa coefficient is 0.90, which has good application prospects. And the effect of only using the point cloud feature is also good, overall accuracy is 94.2%. However, the effect of classification only using waveform features is poor, overall accuracy is 82.33%. **Conclusion** Based on the experiment of waveform decomposition and land cover classification, the following three conclusions can be drawn: 1) The classification effect of using only the point cloud feature (overall accuracy 94.2%) is significantly better than using only waveform feature (overall accuracy 82.33%). However, it still has the problem that building points are confused with bare ground and low vegetation, and a large number of bare ground points are misclassified into vegetation. 2) The classification effect of feature non-selective fusion is improved compared with using only one type of feature (overall accuracy 95.4%). Both TypeI error and TypeII error of building classification are significantly reduced (3%-4%),

and TypeI error of low vegetation and high vegetation is also reduced (1%-2%). 3) It can derive from the result of feature selection that amplitude A and half-wave width σ in waveform features are better than others. In point cloud features, maximum negative height difference (MN), maximum positive height difference (MP), point cloud density (PD), elevation variation range (ER), and step-count (S) rank higher.

Key words: Airborne LiDAR, Full-waveform data, Waveform decomposition, Feature fusion, Land-cover classification

CLC number: P237

Document code: A

本论文参加（参加/不参加）第六届全国激光雷达大会优秀青年论文评选。第一作者的身份证号码为：372930199806194099（参加优秀青年论文评选者填写）。